INSTITUTO TECNOLÓGICO DE QUERÉTARO · TecNM

Maestría · Visión Artificial

Actividad — Sesión 3: Transformada de Hough y detección de esquinas (Harris)

Dr. Víctor Alejandro González Huitrón

Cada alumno desarrolla la actividad correspondiente a su **perfil de proyecto**. Las cinco variantes parten de los fundamentos vistos en la sesión 3 —**la Transformada de Hough para detección de formas paramétricas (líneas y círculos) y el detector de esquinas de Harris**— pero se anclan al dominio de cada proyecto. El trabajo se realiza fuera del horario de clase y se revisa en la siguiente sesión. La evaluación usa una **rúbrica común** (al final de este documento) para las cinco actividades.

Perfil 1 — Red IoT para datos médicos (Raspberry Pi)

Geometría como metadato compacto: enviar líneas en lugar de imágenes

El objetivo es explotar la Transformada de Hough para representar de forma **extremadamente compacta** la estructura reticular de un documento médico (por ejemplo, la rejilla de un formato de laboratorio, tiras reactivas alineadas o los bordes de una placa). En lugar de transmitir la imagen completa por la red, el nodo emisor detecta las líneas dominantes y envía únicamente sus parámetros **(ρ, θ)**, que el receptor usa para reconstruir la geometría.

El alumno implementa el pipeline en el nodo emisor (la Raspberry Pi):

1. detección de bordes (Canny) sobre la imagen en escala de grises;
2. Transformada de Hough de líneas construyendo el acumulador **A[ρ, θ]** y explicando en el reporte la ecuación de voto **ρ = x·cos θ + y·sin θ**;
3. selección de picos por umbral y supresión de no-máximos;
4. serialización de la lista de parámetros **(ρ, θ)** (retomando el esquema .proto de Protocol Buffers de sesiones previas) y su transmisión.

La actividad conecta dos ideas del proyecto: la geometría de la escena puede describirse con **unos pocos números** (crítico en un sistema IoT con ancho de banda limitado), pero la detección **consume ciclos de CPU en un dispositivo embebido**. El alumno mide ambos lados: cuántos bytes se ahorran al enviar parámetros frente a la imagen (RAW/PNG/JPEG) y cuánto cuesta calcular el acumulador en la Raspberry Pi.

Consideración de eficiencia

Se pide comparar el costo del acumulador para **al menos dos resoluciones** de la rejilla (por ejemplo, $\Delta\theta = 1°$ frente a $\Delta\theta = 2°$) y discutir el compromiso entre precisión de las líneas recuperadas y tiempo de cómputo en la plataforma objetivo.

Entregables. Código del pipeline (bordes → Hough → selección de picos → serialización); tabla comparativa del tamaño del payload de los parámetros (ρ, θ) frente a la imagen sin comprimir y comprimida en JPEG; tiempo de cómputo del acumulador en la Raspberry Pi para al menos dos resoluciones de rejilla; imagen con las líneas reconstruidas a partir de los parámetros transmitidos; y una discusión de la compensación entre fidelidad geométrica, peso del mensaje y latencia.

Perfil 2 — Detección de anomalías en mastografía

Hough de círculos para hallazgos redondeados y Harris como anclas de registro

El alumno trabaja con imágenes mamográficas (escala de grises, bajo contraste) y aplica las dos técnicas de la sesión a estructuras de interés clínico, explicando el fundamento de cada una en el reporte:

- **Transformada de Hough de círculos:** tras realzar el contraste (CLAHE, de la sesión 1) y detectar bordes, localiza estructuras aproximadamente circulares —nódulos, marcadores metálicos o microcalcificaciones agrupadas— usando la parametrización $\mathbf{(x-a)^2 + (y-b)^2 = r^2}$. El alumno explica por qué el espacio de parámetros es 3D (a, b, r) y aprovecha la dirección del gradiente para reducir votos.
- **Detector de Harris:** detecta esquinas repetibles (por ejemplo, en marcadores o en la frontera del músculo pectoral) que sirvan como **puntos de anclaje** para registrar dos vistas de la misma mama (CC vs. MLO) o dos estudios en el tiempo.

El propósito es evidenciar que Hough localiza **formas globales** aun con bordes fragmentados por el bajo contraste, mientras que Harris aporta **puntos localizables** para alineación. El alumno debe barrer el rango de radios buscado y el umbral de votos, y argumentar cómo controlar los falsos positivos propios de la mama densa.

Consideración de robustez

Debe comparar la detección de círculos **con y sin el paso de realce de contraste** previo, mostrando cómo mejora el número y la nitidez de los picos en el acumulador.

Entregables. Visualizaciones lado a lado (original / bordes / círculos detectados con Hough); mapa de respuesta de Harris con los keypoints marcados; explicación conceptual de ambos métodos y de por qué aplican a imagen médica; barrido de radios y umbral con la región de interés resaltada; y una discusión del efecto del realce de contraste sobre la calidad de la detección.

Perfil 3 — Reconstrucción 3D para ADAS

Líneas de carril con Hough y keypoints Harris para correspondencia estéreo

El alumno aborda los dos usos que la geometría tiene en un sistema ADAS, comparándolos bajo condiciones de operación realistas:

- **Detección de carriles con Hough de líneas:** a partir de una imagen de carretera (propia o de un banco como KITTI), aplica una región de interés, detecta bordes y usa Hough para extraer las **líneas de carril**. Debe explicar la parametrización (ρ, θ) y por qué es robusta a marcas de carril discontinuas (huecos).
- **Keypoints de Harris para estéreo:** detecta esquinas en las imágenes izquierda y derecha del par y evalúa su **repetibilidad** —cuántos keypoints detectados en una vista tienen correspondencia en la otra—, base de la triangulación para estimar profundidad.

El alumno debe **simular condiciones adversas** (por ejemplo, tres niveles de iluminación —buena, atardecer y noche— o una diferencia de brillo/ganancia entre las cámaras del par) y evidenciar cómo se degradan tanto las líneas de Hough como los keypoints de Harris. Debe explicar por qué Harris es **invariante a rotación pero no a escala**, y qué implica eso al variar la distancia a los objetos.

Consideración de robustez

Para los keypoints, debe reportar una **tasa de repetibilidad** entre la vista izquierda y la derecha y discutir en qué condición de iluminación se pierde más correspondencia y por qué.

Entregables. Código de ambas detecciones (Hough de carriles y Harris estéreo); imágenes con las líneas de carril superpuestas en las tres condiciones de iluminación; mapas de keypoints en las vistas izquierda/derecha con la tasa de repetibilidad; análisis comparativo de robustez indicando dónde falla cada método y por qué; y una nota sobre el manejo de bordes de la imagen en el detector.

Perfil 4 — Análisis de YOLO en plataformas ARM

Implementación y costo en ARM del acumulador de Hough y del score de Harris

Práctica centrada en la programación de bajo nivel y su costo en la plataforma embebida. El alumno implementa **desde cero** los dos núcleos de cómputo vistos en clase y mide su impacto real en el objetivo ARM:

- **Acumulador de Hough:** implementa el bucle de votación (por cada píxel de borde, recorrer Nθ ángulos y actualizar **A[ρ, θ]**). Analiza el costo **O(E · Nθ)**, con E el número de píxeles de borde, y el patrón de acceso a memoria del acumulador.
- **Score de Harris:** implementa el pipeline gradientes → productos I_x^2, I_y^2, I_xI_y → suavizado → **R = det(M) − k·(tr M)²**. Verifica que R separa correctamente plano, borde y esquina, y evita la descomposición explícita en eigenvalores.

El alumno debe **cronometrar cada núcleo en la plataforma ARM** y estudiar cómo escala el costo: para Hough, variando la densidad de bordes y la resolución de la rejilla; para Harris, variando el tamaño de la ventana de suavizado. La práctica conecta con su tesis porque estos operadores clásicos, de costo **predecible y medible**, son un punto de comparación frente al costo de las capas convolucionales del pipeline de inferencia de YOLO.

Consideración de eficiencia

Debe discutir qué parte de cada algoritmo es **paralelizable** (por ejemplo, la votación por píxel o el cálculo de R por píxel) y estimar el beneficio potencial de vectorización SIMD (NEON) en ARM, aunque no se implemente.

Entregables. Código de ambos núcleos (acumulador de Hough y score de Harris); imágenes de salida que confirmen la corrección (líneas detectadas y esquinas marcadas); tablas de tiempos de ejecución en la plataforma ARM variando los parámetros indicados (densidad de bordes / resolución de rejilla para Hough; tamaño de ventana para Harris); y una discusión que relacione estos costos con el de una capa convolucional en la inferencia de YOLO.

Perfil 5 — Indicadores clínicos de diabetes con Deep Learning (datos tabulares y temporales)

De la votación de Hough a la detección de picos y estructura en señales de indicadores

Este perfil no procesa imágenes, sino **datos tabulares y series temporales** de indicadores médicos relacionados con la diabetes (por ejemplo, glucosa continua, HbA1c, IMC, presión, registros de insulina). La actividad **traslada la intuición geométrica de la sesión** —acumular evidencia local para decidir algo global— al dominio del alumno, preparando el terreno para los modelos de aprendizaje profundo (CNN / LSTM y variantes) que usará en su tesis.

El alumno realiza dos ejercicios conceptualmente análogos a Hough y Harris:

- **Analogía de Hough (votación → picos):** sobre una señal de glucosa (o el indicador que elija), implementa una **detección de picos por acumulación de evidencia**. La idea es la misma que el

acumulador: en vez de umbralizar punto por punto, cada muestra 'vota' según su vecindad (por ejemplo, con una ventana deslizante o un histograma de pendientes) y los **máximos locales robustos** corresponden a eventos —hiperglucemias postprandiales, patrones recurrentes—. Debe explicar por qué la acumulación es más robusta al ruido que un umbral simple, igual que Hough tolera bordes fragmentados.

- **Analogía de Harris (puntos de interés):** define y detecta **puntos de interés temporales** —instantes donde la señal 'cambia mucho en su vecindad'— usando una medida análoga a la respuesta de Harris: la **variación local** de la señal (por ejemplo, la energía de la derivada en una ventana). Estos keypoints temporales marcan transiciones informativas que un modelo debería atender.

Finalmente, el alumno conecta explícitamente con el **esquema de DL** de su tesis: argumenta cómo una **CNN 1D** aprende, en sus primeras capas, filtros que responden a estos mismos patrones locales (picos, flancos) —igual que las primeras capas de una CNN de imagen convergen a detectores de borde—, y cómo una **LSTM** complementa capturando la dependencia temporal de largo alcance entre esos eventos. No se exige entrenar el modelo final: se exige **dejar preparado el pipeline de características** y justificar la elección de paradigma.

Consideración de datos

El alumno usa un conjunto público (por ejemplo, un dataset de monitoreo continuo de glucosa o el **Pima Indians Diabetes** para la parte tabular) y documenta el preprocesamiento (normalización, manejo de faltantes, ventaneo), de modo que el trabajo sea reproducible.

Entregables. Código del detector de picos por acumulación y del detector de puntos de interés temporales; visualizaciones de la señal con los picos y los keypoints marcados; comparación del detector por acumulación frente a un umbral simple (robustez al ruido); una tabla o esquema de las características extraídas que alimentarían una CNN 1D / LSTM; y una discusión que justifique el paradigma de DL elegido y trace el paralelo con lo visto en clase (votación/acumulación y puntos de interés).

Rúbrica de evaluación (común a las cinco actividades)

Cada actividad se califica con los mismos cinco criterios. La escala por criterio es de 0 a 4; la calificación final pondera cada criterio según su peso. El **nivel Suficiente** corresponde a un desempeño aceptable con áreas de mejora; el **nivel Excelente**, a un trabajo completo, correcto y bien argumentado.

Criterio	Excelente (4)	Suficiente (2-3)	Insuficiente (0-1)	Peso
Corrección técnica	La técnica del perfil se implementa correctamente y produce el resultado esperado sin errores.	Se implementa con errores menores o resultados parcialmente correctos.	No se implementa o el resultado es incorrecto.	**30%**
Dominio conceptual	Explica con precisión los fundamentos (Hough / Harris) y por qué aplican a su dominio.	Explica de forma general, con imprecisiones o sin conectar con el dominio.	No explica o los conceptos son erróneos.	**25%**
Análisis y comparación	Compara alternativas o condiciones con evidencia (métricas, tiempos o visuales) y extrae conclusiones válidas.	Presenta comparación superficial o sin conclusiones claras.	No hay comparación ni análisis.	**20%**
Evidencia y visualizaciones	Entrega visualizaciones claras y rotuladas que sustentan cada afirmación.	Entrega evidencia incompleta o poco clara.	Evidencia ausente o ilegible.	**15%**
Reporte y reproducibilidad	Reporte ordenado; el trabajo puede reproducirse (código/entorno documentado).	Reporte comprensible pero difícil de reproducir.	Reporte desordenado o no reproducible.	**10%**

Cálculo de la calificación: suma ponderada de los cinco criterios sobre la escala de 4, normalizada a la escala del curso. Un criterio en 0 indica ausencia total del componente; en 4, cumplimiento pleno del descriptor Excelente.